Predicción del precio de productos en Amazon mediante técnicas de aprendizaje automático

Entregable I - Proyecto de aula

Ana María G. Giraldo[1], Sebastián B. Ruiz[2] y Juan F. Mona Cano[3]

[1]*Facultad de Ingeniería, Universidad de Antioquia*

Anam.garzon@udea.edu.co, s.barrera@udea.edu.co, juanf.mona@udea.edu.co

Resumen— El análisis de datos de productos de comercio electrónico permite estudiar las relaciones entre sus características comerciales y su comportamiento de ventas. Este trabajo plantea el análisis de un conjunto de datos de productos de Amazon con el propósito de identificar patrones y establecer una base metodológica para predecir su desempeño comercial a partir de variables como el precio, la calificación y el número de reseñas. Se describen las características del conjunto de datos, las actividades de limpieza y transformación de variables, y las consideraciones asociadas con los valores faltantes y las observaciones extremas. Asimismo, se fundamenta el uso del aprendizaje supervisado como enfoque para abordar el problema mediante una tarea de regresión, tomando como variable objetivo el volumen aproximado de compras recientes. Finalmente, se examinan investigaciones relacionadas con la estimación de precios, la detección de precios incorrectos y la fijación dinámica de precios en el comercio electrónico. El trabajo establece una base teórica y metodológica para el desarrollo posterior de modelos predictivos, sin atribuir resultados experimentales a modelos aún no evaluados.

Términos índice—Aprendizaje automático, comercio electrónico, desempeño comercial, predicción de ventas, regresión.

I. INTRODUCCIÓN

El crecimiento del comercio electrónico ha transformado la manera en que las empresas comercializan sus productos y recopilan información sobre el comportamiento de los consumidores. Las plataformas digitales generan grandes cantidades de datos relacionados con las características de los productos, sus precios, las valoraciones de los compradores, las estrategias promocionales y las señales de popularidad comercial. Esta información constituye una fuente potencial para analizar las relaciones entre las características observables de los productos y su desempeño en el mercado. En este contexto, las técnicas de análisis de datos y aprendizaje automático ofrecen herramientas para identificar patrones que pueden resultar difíciles de reconocer mediante una inspección exclusivamente manual.

Uno de los problemas de interés en este ámbito consiste en estimar el desempeño comercial de un producto a partir de la información disponible en su ficha de publicación. Variables como el precio, la calificación promedio, el número de reseñas, la presencia de descuentos y las condiciones de entrega pueden aportar información complementaria sobre el comportamiento de los productos. Sin embargo, la relación entre estos atributos y la demanda no es necesariamente lineal ni uniforme: una misma característica puede relacionarse de manera diferente con el comportamiento comercial dependiendo de otros factores presentes en los datos. Por ello, resulta pertinente estudiar conjuntamente múltiples variables y considerar métodos capaces de representar relaciones complejas.

Diversas investigaciones han abordado problemas relacionados con la predicción de la demanda, el desempeño de ventas y las calificaciones de productos en plataformas electrónicas [1]–[5]. Estos trabajos muestran la variedad de objetivos que pueden estudiarse a partir de información comercial y permiten contextualizar el uso de técnicas predictivas en este dominio. No obstante, la predicción de ventas, la estimación de calificaciones y la identificación de factores asociados con la demanda corresponden a tareas distintas, por lo que sus metodologías y resultados deben interpretarse de acuerdo con la variable objetivo de cada investigación.

II. FORMULACIÓN DEL PROBLEMA Y DESCRIPCIÓN DE LOS DATOS

A. Formulación del problema

El desempeño comercial de un producto puede representarse mediante distintos indicadores, como el volumen de ventas, los ingresos generados o su posición relativa frente a otros productos. La elección del indicador depende tanto del objetivo del análisis como de la información disponible. En el conjunto de datos considerado, el atributo Current/discounted_price proporciona los precios actuales, sea un precio con descuento aplicado o uno sin este, del producto y, por tanto, constituye una alternativa para representar cuantitativamente el comportamiento comercial de cada producto.

El problema se formula como la estimación de dicha variable a partir de las características observables de los productos. Entre los predictores potenciales se encuentran las compras recientes, la calificación, el número de reseñas y distintos indicadores comerciales, como la presencia de cupones, el patrocinio, la condición de producto destacado y la disponibilidad de compra. También pueden considerarse atributos derivados del título y de la información de entrega, siempre que su construcción sea consistente y que su disponibilidad sea compatible con el escenario de predicción planteado.

Desde el punto de vista del aprendizaje automático, esta formulación corresponde a un problema de regresión, puesto que se busca estimar una cantidad numérica a partir de ejemplos que contienen tanto las variables predictoras

como el valor objetivo. El modelo deberá aprender las relaciones presentes en los registros de entrenamiento y utilizar lo aprendido para producir estimaciones sobre productos no empleados durante el ajuste. La utilidad de esta aproximación dependerá de la capacidad de generalización del modelo y de la calidad con la que la variable objetivo represente el fenómeno de interés.

B. Descripción del conjunto de datos

El conjunto de datos utilizado es Amazon Product Sales Data—42K Items, publicado en Kaggle [6]. La versión examinada contiene inicialmente 42 675 registros y 16 columnas, correspondientes a información descriptiva, comercial y auxiliar de los productos. Entre las variables se encuentran el título, la calificación promedio, el número de reseñas, las compras reportadas durante el último mes, los precios actuales y de lista, y varios indicadores relacionados con la promoción y la disponibilidad. También se incluyen datos sobre la entrega, las insignias de sostenibilidad, los enlaces del producto y la fecha de recopilación.

Estas variables presentan distintos niveles de utilidad para el problema planteado. Los precios permiten representar el costo de adquisición y comparar diferencias entre productos; las calificaciones y las reseñas ofrecen señales relacionadas con la experiencia y la participación de los consumidores; mientras que los indicadores de cupones, patrocinio y condición de producto destacado describen aspectos de la presentación comercial. La disponibilidad de compra y la información de entrega también pueden aportar contexto sobre las condiciones bajo las cuales un producto puede ser adquirido. Sin embargo, la presencia de una variable en el conjunto de datos no garantiza que sea un predictor útil: su contribución deberá analizarse posteriormente mediante procedimientos adecuados y sin utilizar información que no estaría disponible en el momento de realizar una predicción.

La estructura del conjunto también impone restricciones. Algunos atributos son principalmente metadatos, como los enlaces a imágenes o productos y la fecha de recopilación. Otros campos contienen texto o etiquetas que deben transformarse antes de poder utilizarse en un modelo numérico.

La presencia de valores faltantes y representaciones heterogéneas constituye otra característica relevante del conjunto. Algunas columnas contienen cantidades numéricas almacenadas como texto, mientras que otras utilizan indicadores, descripciones o campos parcialmente vacíos. Esta heterogeneidad hace necesario distinguir entre la estructura original de los datos y la representación preparada para el análisis.

TABLA I
CONJUNTO DE DATOS ORIGINAL

Característica/Columna	Descripción
Title	Nombre/título del producto
Rating	Calificación del cliente (Entre 0 y 5 estrellas)
Number_of_reviews	Número de reseñas de clientes
bought_in_last_month	Recuento de compras recientes
Current/discounted_price	Precio de venta actual
Price_on_variant	Precio de otra variante del mismo producto (color, talla, tamaño)
Listed_price	Precio listado original (antes del descuento en caso de tenerlo)
is_best_seller	Estado de mejor vendedor (El producto es de los más vendidos de su clase)
is_sponsored	Estado del producto patrocinado (el vendedor pagó a Amazon para aparecer destacado)
is_couponed	Disponibilidad del cupón
buy_box_availability	Disponibilidad de compra
delivery_details	Información de entrega
sustainability_badges	Insignias relacionadas con la sostenibilidad
image_url	Enlace de imagen del producto
product_url	Enlace a la página del producto
collected_at	fecha y hora de recopilación de datos

C. Valores faltantes y preparación de datos

La preparación de los datos constituye una etapa fundamental ya que las inconsistencias presentes en los registros pueden afectar tanto el análisis exploratorio como el ajuste posterior de los modelos. En esta sección, se pretende documentar la eliminación de duplicados, la conversión de variables numéricas almacenadas como texto, la creación de indicadores binarios y la construcción de atributos derivados, en otras palabras, hacer una limpieza masiva al conjunto de datos original. Entre estas operaciones se encuentran la conversión de precios y cantidades de reseñas, la codificación de indicadores comerciales y la extracción de características sencillas del título y de la información de entrega.

Una de las principales dificultades se encuentra en el tratamiento de los valores faltantes. La versión analizada presenta ausencias en atributos como la calificación, el número de reseñas, las compras recientes, los precios y la información de entrega. La estrategia de tratamiento debe responder a la naturaleza de cada variable y al significado que puede atribuirse a su ausencia. Por ejemplo, imputar una calificación con la media supone sustituir la información faltante por un valor representativo de la distribución observada, pero puede reducir la variabilidad de la variable y no refleja necesariamente la calificación que habría tenido el producto.

Por otra parte, el análisis de observaciones atípicas permite identificar valores que se alejan considerablemente del comportamiento central de una variable. El rango intercuartílico (IQR) ofrece un criterio para detectar valores por debajo o por encima de límites definidos a partir de los

cuartiles. Sin embargo, este procedimiento identifica observaciones extremas desde una perspectiva estadística, no necesariamente errores de captura. En un contexto comercial, un producto con muchas compras o un precio elevado puede corresponder a un caso legítimo y relevante. En consecuencia, la exclusión de observaciones debe justificarse en función de su validez y del objetivo de investigación, puesto que puede alterar la distribución de la variable objetivo y limitar la representación de productos con demanda excepcionalmente baja o alta.

Finalmente, las transformaciones logarítmicas exploradas pueden ayudar a reducir la asimetría de variables con valores positivos y escalas amplias. Estas transformaciones no eliminan automáticamente todos los problemas de distribución, pero pueden facilitar el análisis y el ajuste de ciertos modelos. Para mantener la validez de la evaluación predictiva, cualquier transformación o procedimiento de imputación que estime parámetros a partir de los datos debe ajustarse con el conjunto de entrenamiento y aplicarse posteriormente a los datos de validación o prueba.

TABLA II
LIMPIEZA DE DATOS

Variable	Rol	Tipo original	Codificación propuesta	Faltantes
Title	Entrada	Texto libre	Palabras clave / marca; opcional TF-IDF	Sin nulos
Rating	Entrada	Texto	Extraer valor numérico	1 024; evaluar imputación o eliminación
Number_of_reviews	Entrada	Texto	Convertir a entero	Mismos 1 024 de Rating
bought_in_last_month	Entrada	Ordinal	Usar límite inferior	3 217; inicialmente 0
Listed_price	Entrada	Texto	Convertir a decimal	Sin nulos
is_best_seller	Entrada	Categórica nominal	One-Hot Encoding	Sin nulos; “No Badge” como categoría
is_sponsored	Entrada	Binaria	Codificación 0/1	Sin nulos
is_coupoened	Entrada	Categórica	Porcentaje + bandera de cupón	Sin nulos
buy_box_availability	Entrada	Binaria	1 si “Add to cart”; 0 en otro caso	Nulos = no disponible
delivery_details	Entrada	Texto	Calcular días hasta entrega	Evaluar mediana o descarte
sustainability_badges	Entrada opcional	Categórica dispersa	Bandera tiene/no tiene insignia	92 %; evaluar permanencia
Current/discounted_price	Objetivo	Texto	Convertir a decimal	Eliminar filas sin dato

III. FUNDAMENTACIÓN DEL ENFOQUE DE APRENDIZAJE

El aprendizaje automático comprende métodos computacionales que permiten construir modelos a partir de datos con el propósito de identificar regularidades y realizar estimaciones sobre observaciones nuevas. En términos generales, la elección del paradigma de aprendizaje depende de la disponibilidad de una variable objetivo, de la naturaleza de la tarea y de la forma en que se pretende utilizar los resultados. En el problema estudiado, el conjunto de datos incluye un atributo que puede emplearse como referencia cuantitativa del comportamiento comercial, por lo que el aprendizaje supervisado constituye una alternativa metodológica coherente, sujeta a la calidad de dicha variable.

Dentro de este paradigma, la regresión busca estimar una variable numérica a partir de un conjunto de características de entrada. A diferencia de una tarea de clasificación, en la que el resultado corresponde a una clase o categoría, la regresión pretende producir una estimación de magnitud. En este caso, el objetivo sería identificar patrones en los datos de productos y predecir su desempeño comercial, utilizando como entradas las características comerciales y descriptivas disponibles.

La selección de un paradigma de regresión no presupone que las variables mantengan relaciones lineales ni que todas tengan la misma importancia predictiva. La relación entre los atributos y las compras puede ser compleja, y la contribución de una variable puede depender de la presencia de otras características. Por este motivo, la selección definitiva del algoritmo debe sustentarse en una evaluación empírica, comparando las predicciones obtenidas por modelos apropiados frente a una referencia sencilla. La complejidad de un modelo, por sí sola, no garantiza un mejor desempeño ni una mayor capacidad de generalización.

La evaluación de los modelos debe utilizar datos que no hayan intervenido en su ajuste y métricas coherentes con la variable objetivo. El error absoluto medio (MAE) permite medir la magnitud promedio de los errores absolutos en las unidades originales de la variable. La raíz del error cuadrático medio (RMSE) asigna mayor peso a los errores de gran magnitud, mientras que el coeficiente de determinación (R^2) compara el ajuste del modelo con la variabilidad de la variable objetivo respecto a su media. Estas métricas proporcionan perspectivas complementarias y deben interpretarse considerando la distribución de las compras y las limitaciones de su representación numérica.

La aplicación de estas medidas requiere establecer previamente una estrategia de partición de los datos, definir las variables predictoras y controlar la fuga de información. También debe evaluarse si el filtrado de productos con compras nulas o valores extremos modifica de manera importante la población sobre la que se desea generalizar. En consecuencia, el enfoque propuesto no consiste únicamente en seleccionar un algoritmo, sino en definir un procedimiento reproducible que relacione la calidad de los datos, la construcción de la variable objetivo, el entrenamiento y la evaluación del modelo.

IV. TRABAJOS RELACIONADOS

La investigación sobre aprendizaje automático aplicado al comercio electrónico abarca distintas tareas, entre ellas la predicción de demanda, la estimación del desempeño de ventas, la predicción de calificaciones y la estimación de precios. Aunque estos problemas comparten el uso de información comercial y características de productos, difieren en la variable que se busca estimar y en las decisiones metodológicas que requiere cada tarea. La revisión de estos antecedentes permite situar el problema estudiado dentro de un campo de aplicación más amplio, al tiempo que ayuda a distinguir las contribuciones que pueden trasladarse metodológicamente de aquellas que dependen de conjuntos de datos y objetivos específicos.

Chong et al. [1] estudiaron la predicción de la demanda de productos mediante información relacionada con las reseñas en línea y las estrategias de promoción. Este antecedente resulta pertinente porque considera señales comerciales semejantes a algunas de las disponibles en el conjunto analizado, como las valoraciones y las promociones. Su planteamiento permite contextualizar el interés por estudiar conjuntamente atributos del producto y señales de interacción de los consumidores, en lugar de considerar el precio como el único elemento asociado con el desempeño comercial. Li et al. [2], por su parte, analizaron el desempeño de ventas en mercados electrónicos mediante un enfoque basado en datos, considerando la relación entre distintas características comerciales y el rendimiento observado. Este trabajo refuerza la pertinencia de estudiar múltiples atributos y de reconocer que sus relaciones con el desempeño pueden depender del contexto y de la interacción entre variables.

En una línea relacionada, Chong et al. [3] abordaron la predicción de ventas en línea mediante una arquitectura que combina información de reseñas, análisis de sentimientos y estrategias promocionales con redes neuronales. La relevancia de este estudio reside en su integración de fuentes de información y en la consideración de señales textuales y comerciales dentro de un mismo planteamiento predictivo. Aunque el conjunto de datos del presente trabajo no necesariamente contiene todos los atributos empleados por estos autores, el antecedente permite justificar la exploración de variables relacionadas con reseñas y promociones. Yin y Tao [4] investigaron la predicción de ventas en plataformas de comercio electrónico mediante técnicas de minería de datos y aprendizaje profundo. Su trabajo amplía los antecedentes metodológicos sobre el uso de modelos capaces de identificar relaciones complejas en datos comerciales; sin embargo, las diferencias entre las plataformas, las variables objetivo y las representaciones de ventas deben considerarse antes de comparar directamente los resultados.

Woo y Mishra [5] estudiaron la predicción de calificaciones de productos de Amazon utilizando técnicas de análisis de datos a gran escala. Aunque las calificaciones constituyen una variable diferente de las compras recientes, este antecedente es relevante por su relación con el dominio de los productos de Amazon y por el tratamiento de información comercial en un escenario de gran volumen de datos. La diferencia entre ambas variables objetivo es importante: un modelo que predice calificaciones no demuestra por sí mismo que sea adecuado para predecir compras, pero su planteamiento puede servir como referencia general para el análisis de datos de productos.

Otros trabajos se concentran específicamente en la estimación y evaluación de precios. Duyku et al. [7] presentan un enfoque de aprendizaje automático para la estimación de precios, mientras que Wu [8] aborda la predicción de precios de productos de comercio electrónico mediante la integración de descomposición modal variacional y redes neuronales profundas. Estas investigaciones se relacionan con el presente trabajo por el uso de características de productos para estimar una variable comercial cuantitativa. No obstante, el precio y el volumen de compras representan fenómenos distintos: el primero corresponde a una condición de comercialización, mientras que el segundo se utiliza aquí como indicador aproximado de demanda. Por tanto, los enfoques de estimación de precios aportan contexto metodológico, pero no constituyen evidencia directa de la capacidad de un modelo para predecir compras recientes.

Toan et al. [9] estudian la identificación y predicción de precios incorrectos mediante modelos de aprendizaje automático. Este problema destaca la importancia de examinar la consistencia de los datos y distinguir los valores atípicos de los errores reales. En el conjunto analizado, esta distinción resulta especialmente pertinente porque los precios elevados y las cantidades de compras excepcionales pueden representar casos legítimos, por lo que no deberían eliminarse únicamente por su distancia respecto a la distribución central. Finalmente, Yoshi et al. [10] abordan la fijación dinámica de precios mediante modelos predictivos e información relacionada con el sentimiento de los consumidores. Este trabajo amplía el contexto de aplicación hacia el uso de modelos para apoyar decisiones comerciales, aunque la optimización de precios constituye un objetivo diferente de la estimación del número de compras.

En conjunto, los antecedentes revisados muestran que el aprendizaje automático se ha aplicado a distintas tareas vinculadas con el comportamiento comercial, desde la predicción de demanda y ventas hasta la estimación de precios y calificaciones. La relación entre estos estudios y el presente trabajo se encuentra principalmente en el uso de atributos de productos, señales de opinión de los

consumidores y características promocionales para construir análisis predictivos. Sin embargo, sus objetivos, datos y procedimientos de evaluación no son necesariamente equivalentes. Por ello, la pertinencia de los métodos deberá establecerse mediante una evaluación sobre el conjunto específico de productos de Amazon utilizado en este estudio, sin asumir que los resultados publicados en otros contextos se reproducirán de manera automática.

REFERENCIAS

[1] A. Y. L. Chong, E. Ch'ng, M. J. Liu, and B. Li, "Predicting consumer product demands via Big Data: the roles of online promotional marketing and online reviews," *International Journal of Production Research*, vol. 55, no. 17, pp. 5142–5156, 2017, doi: 10.1080/00207543.2015.1066519.

[2] B. Li, E. Ch'ng, A. Y. L. Chong, and H. Bao, "Predicting online e-marketplace sales performances: A big data approach," *Computers & Industrial Engineering*, vol. 101, pp. 565–571, 2016, doi: 10.1016/j.cie.2016.08.009.

[3] A. Y. L. Chong, B. Li, E. W. T. Ngai, E. Ch'ng, and F. Lee, "Predicting online product sales via online reviews, sentiments, and promotion strategies: A big data architecture and neural network approach," *International Journal of Operations & Production Management*, vol. 36, no. 4, pp. 358–383, 2016, doi: 10.1108/IJOPM-03-2015-0151.

[4] X. Yin and X. Tao, "Prediction of merchandise sales on e-commerce platforms based on data mining and deep learning," *Scientific Programming*, vol. 2021, Art. no. 2179692, 2021, doi: 10.1155/2021/2179692.

[5] J. Woo and M. Mishra, "Predicting the ratings of Amazon products using Big Data," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 11, no. 3, 2021, doi: 10.1002/widm.1400.

[6] srisyra02, "Amazon Product Sales Data—42K Items," *Kaggle*, 2025. [Online]. Available: https://www.kaggle.com/datasets/srisyra02/amazon-product-sales-data-42k-items-2025

[7] E. Duyku, M. S. Güzel, E. Bostancı, and İ. Askerzade, "A Machine Learning Based Approach for Price Estimation," *Proceedings of IAM*, vol. 11, no. 1, pp. 50–61, 2022.

[8] H. Wu, "Predicting E-commerce Product Prices Through the Integration of Variational Mode Decomposition and Deep Neural Networks," *PeerJ Computer Science*, vol. 10, Art. no. e2353, 2024, doi: 10.7717/peerj-cs.2353.

[9] L. T. Toan, N. X. H. Giang, and N. H. Thuan, "Identify and Predict Incorrect Prices by Machine Learning Model," *CTU Journal of Innovation and Sustainable Development*, vol. 15, no. 2, pp. 35–44, 2023, doi: 10.22144/ctu.jen.2023.018.

[10] A. M. Yoshi, A. Rohan, S. A. Mitu, M. M. K. Rabbi, S. Akther, and K. R. Ahmed, "Real-Time Dynamic Pricing Using Machine Learning: Integrating Customer Sentiment and Predictive Models for E-Commerce," *International Journal of Advanced Computer Science and Applications*, vol. 16, no. 9, 2025, doi: 10.14569/IJACSA.2025.0160904.